



# I'm Something of a Painter Myself

Use GANs to create art - will you be the next Monet?



16

Vincent GAN Gogh



38.55316

Team: Orel Ben Zaken 315628313  
Omer Luxembourg 205500390

## לשים לב:

- לדוח מצורפת מחברת שבה ניתן להריץ אימון והגשה של הארכיטקטורה הטובה ביותר שהתקבלה ובנוסף תחת הכותרת "Train the CycleGAN" מצויין איזה פרמטרים צריך לשנות כדי להריץ אימון של כל אחד מהמודלים המתוארים בדוח.
- את המודל שכולל את ה-אוגמנטציות על הדאטא סט בשלב ה-preprocessing ניתן להריץ רק על ה-cpu וה-gpu.
- בפועל ביצענו את ההרצה על GPU ולשם כך היינו צריכים להעביר את הקוד להיות בקובץ py. כך שיוכל לרוץ על החומרה החיצונית. בקישור ל-git שמוצג מטה ניתן לראות את כל הקבצים של הפרוייקט שבהם השתמשנו לצורך ההרצות על ה-GPU החיצונית.

הקישור ל-git: <https://github.com/omerlux/Something-of-a-Painter>

# Abstract

במסגרת פרוייקט זה אנו צריכים לבנות מודל שידע לקחת תמונה שצולמה ע"י מצלמה ולהמיר אותה לציור בסגנון Monet כלומר אנו צריכים לפתור בעיה מסוג: Image to Image translation.

Image to Image translation זו בעיה שבה המטרה היא ללמוד למפות תמונת Input מתחום מתחום מסויים  $X$  לתמונת Output מתחום אחר  $Y$ . בדרך כלל לומדים את המיפוי באמצעות סט אימון שמכיל צמדים של תמונות משני התחומים אך, בבעיה הספציפית שלנו לא אין לנו צמדים מתאימים של תמונות כלומר, הדאטא סט שלנו מורכב מסט של תמונות שצולמו ע"י מצלמה ומסט של ציורי Monet כאשר אין צמדים מתאימים של תמונות בין שני הסטים.

בפרויקט זה אנו מציגים מודל שנקרא CycleGAN [1] שמאפשר ללמוד את המיפוי בין התחומים למרות הבעיה שאין סט אימון שמורכב צמדים מתאימים. במסגרת הפרוייקט אנחנו מציגים גם את החולשות של מודל זה בגלל הארכיטקטורה עצמה או בגלל הדאטא ואת הדרכים שיכולות לעזור להתמודד עם חולשות אלה.

הדוח מתחיל ב-Introduction שנותן הסבר יותר ספציפי לבעיה זו, לאחר מכן מוצג תיאור של הדאטא (Data Description), השיטה המוצעת (Methods and Algorithms), אתגרים ובעיות שהיו לנו במסגרת העבודה (Challenges and Difficulties) ולבסוף מוצגים תוצאות הניסויים שעשינו (Experiments), התוצאות של המודלים שהגשנו ל-kaggle (Results) ומסקנות וסיכום (Conclusions and Summary).

# Introduction

## מטרת ה-Challenge:

בניית מודל שלוקח תמונה שצולמה ע"י מצלמה ויוצר ציור של אותה תמונה בסגנון הצייר מונה (Monet).

### תיאור מתמטי:

נסמן: ב-  $X$  - תחום המכיל תמונות שצולמו ע"י מצלמה.  
ב-  $Y$  - תחום המכיל ציורי מונה.

אנו צריכים למצוא פונקציה  $G_Y: X \rightarrow Y$  כך שעבור כל תמונה  $x \in X$ , שצולמה ע"י מצלמה, נקבל את הציור מונה  $y \in Y$  המתאים לה, כלומר, נרצה שיתקיים  $y = G_Y(x)$ .

ב-Fig 1 ניתן לראות תיאור ויזואלי של משימה:  
מערכת שה-**input שלה תמונה שצולמה ע"י מצלמה** ו-**output שלה הוא ציור בסגנון מונה של התמונה**.




Fig 1: visual description of the challenge goal

במקרה זה הסט אימון לא מכיל צמדים מתאמים של תמונות משני התחומים ולכן על מנת שנוכל ללמוד את המיפוי בכל זאת ההצעה היא להשתמש במודל ה-CycleGAN [1] (שמוסבר בירור בפרק Methods and Algorithms).

הרעיון הכללי של CycleGAN הוא ללמוד את פונקציית המיפוי הרצויה וגם את הפונקציית מיפוי ההופכית: מכיוון שהסט אימון לא מורכב מצמדים מתאמים, אז על מנת שנוכל ללמוד את פונקציית המיפוי, ה-generator,  $G_Y: X \rightarrow Y$  כך שייצר תמונות שבאות מההתפלגות של קבוצת התמונות  $Y$  באמצעות ה-adversarial loss, אנו לומדים גם פונקציית היפוך  $G_X: Y \rightarrow X$  ובאמצעות פונקציית  $loss$ , שנקראת  $cycle consistency loss$ , אנו "מכריחים" את המודל  $G_Y$  לשמור תכונות חשובות של ה-input כך שיהיה ניתן לשחרר את ה-input. דרך זו אמורה לעזור ל- $G_Y$  ללמוד איך להמיר תמונה מתחום  $X$  לתמונה המתאימה לו מתחום  $Y$  ע"י כך שפונקציית המיפוי לומדת תכונות חשובות מה-input ושומרת אותן.

\*הסבר מפורט יותר על המודל וה- $loss$ -ים יוסברו בפרק Methods and Algorithms.

# Data Description

הדאטא סט באתגר Kaggle זה מכיל תמונות RGB משני סוגים: ציורי Monet ותמונות שצולמו ע"י מצלמה PHOTOS.

התמונות לא מסודרות בצמדים מתאימים משני הסוגים, כלומר, לכל ציור Monet שיש בדאטא אין תמונה PHOTO שמתאימה לו.

התפלגות התמונות לפי שני הסוגים מתוארת ב-bar plot שב-Fig 2.

מה-bar plot נובע שיש חוסר איזון בין שני סוגי התמונות, כמות התמונות של ה-Monet מהווה בערך 4 מהדאטא כולו ושאר הדאטא מכיל תמונות PHOTOS.

חוסר האיזון יכול להשפיע על המודל במהלך האימון בכך שה-discriminator יכול להיכנס למצב של overfitting וההשפעה מוסברת בפירוט בפרק Challenges and Difficulties.

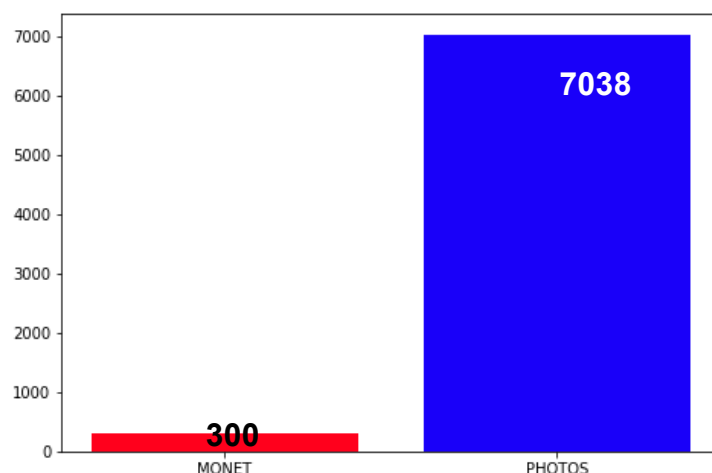


Fig 2: bar plot of the images in the data set per type (Monet or PHOTOS).

בנוסף ב-Fig 3 מוצגות 3 היסטוגרמות שמתארות את ההתפלגות של ערכי הפיקסל בכל ערוץ עבור הסט Monet (אדום) ועבור הסט PHOTOS (כחול).

מההיסטוגרמות ניתן לראות שההתפלגות של ערך הפיקסל בכל ערוץ עבור הסט Monet שונה מההתפלגות המתקבלת עבור הסט PHOTOS והמטרה באתגר Kaggle זה היא לתכנן מודל שילמד למפות תמונה מההתפלגות של Monet לתמונה המתאימה לה מההתפלגות של PHOTOS.

\*המרנו את הערכים של הפייקסלים בכל תמונה להיות בתחום  $[-1,1]$ .

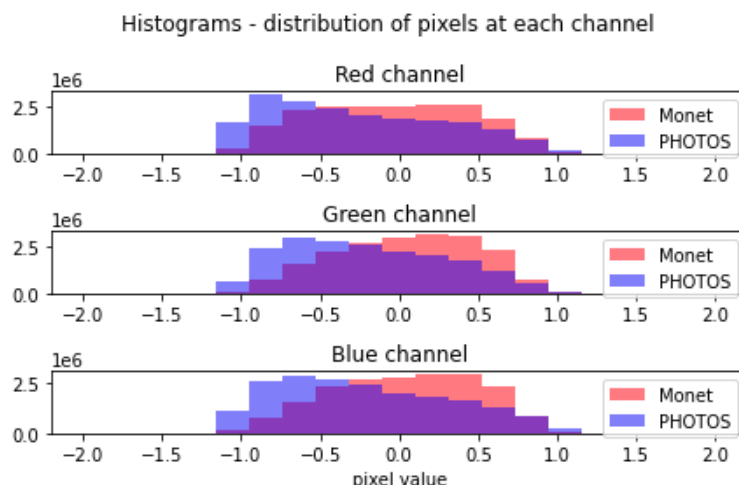


Fig 3: Histograms-distribution of pixels at each channel.

# Methods and Algorithms

## המודל CycleGAN [1]:

מה זה CycleGAN:

סוג של GAN שמאפשר ללמוד טרנספורמציה של תמונה מתחום  $X$  לתמונה מתחום  $Y$  כאשר לא נתונים הזוגות המתאימים. כלומר לכל תמונה  $x_i \in X$  לא נתון  $y_i \in Y$  המתאימה לה.

המטרה שלנו היא למצוא פונקציית מיפוי  $G_Y: X \rightarrow Y$  כך שהתמונות מ- $G_Y(X)$  יהיו מההתפלגות של  $Y$ .  
אם נשתמש במודל GAN קלאסי עם adversarial loss בלבד, אז לכל תמונה  $x_i \in X$  מיפוי זה יכול לתת תמונה כלשהי מתוך מתחום  $Y$  ואנו רוצים את התמונה  $y_i \in Y$  המסוימת שמתאימה לתמונה  $x_i$ .  
לכן, כדי להגביל את המיפוי של הפונקציה  $G_Y$  ה-CycleGAN לומד את המיפוי ההופכי  $G_X: Y \rightarrow X$  ובאמצעות שימוש ב-cycle consistency loss (שיוסבר בהמשך) "מכריחים" את הפונקציה  $G_Y, G_X$  לשמור תכונות של ה-input שלהן כך שיתקיים:  
 $G_X(G_Y(x)) \approx x, G_Y(G_X(y)) \approx y$

### הקשר בין המודל לבעיה שלנו:

- במקרה שלנו  $X$  זה התחום של התמונות שצולמו ע"י מצלמה ו- $Y$  זה התחום של הציורי Monet.
- אנו רוצים למצוא פונקציה  $G_Y: X \rightarrow Y$  שלוקחת תמונה שצולמה ע"י מצלמה והופכת אותה לציור בסגנון Monet המתאים. כלומר, פונקציית המיפוי צריכה לשמור ולזהות תכונות של input על מנת שתוכל להציג אותם כציור.
- אם נשתמש במודל GAN הקלאסי עם ה-adversarial loss בלבד, פונקציית המיפוי יכולה לתת לנו במוצא ציור כלשהו של Monet שלא קשור ל-input שהוא תמונה ממצלמה ואנו רוצים שהמערכת תיצור ציור ספציפי בסגנון Monet של ה-input.

הסיבה לשימוש ב-CycleGAN בבעיה שלנו:

באמצעות שימוש ב-CycleGAN ניתן "להכריח" את פונקציית המיפוי  $G_Y$  ללמוד תכונות של ה-input כך שבמוצא נקבל תמונה שנראית כמו ציור בסגנון Monet של ה-input (תמונה שצולמה ע"י מצלמה).

### הארכיטקטורה של ה-CycleGAN:

כפי שמתואר ב-Fig 4 המודל כולל שתי פונקציות מיפוי  $G_Y: X \rightarrow Y, G_X: Y \rightarrow X$  (generators) ובנוסף שני discriminator-ים  $D_X, D_Y$ .  
כאשר,  $D_X$  מטרתו להבחין בין תמונה אמיתית שצולמה ע"י מצלמה לבין "זיוף" ו- $D_Y$  מטרתו להבחין בין ציור Monet אמיתי לבין "זיוף".




Fig 4: CycleGAN model

**ארכיטקטורה של ה-generators:**  
 בכל אחד מה-generators השתמשנו בארכיטקטורה שמבוססת על U-Net.




Fig 5: example for U-Net architecture

**ארכיטקטורה של ה-discriminators:**  
 אנו משתמשים בארכיטקטורה שמתאמה לגישת PatchGAN [2], שכבות קונבולוציה ו-down samples כאשר במוצא כל discriminator מקבלים patch בגודל  $30 \times 30$  כפי שמתואר ב-Fig 6.  
 כל פיקסל  $ij$  ב-patch בגודל  $30 \times 30$  מייצג האם ה-patch ה- $ij$  בתמונה (ה-input) הוא real או fake.

\* כדי לדעת איזה patch מהתמונה המקורית מתאים לפיקסל  $ij$  במוצא ה-discriminator, אפשר להתחקות אחרי ה-receptive field שמתאים לו.

\* מתמטית שימוש ב-discriminator בגישת PatchGAN שקול למצב שבו היינו "חותכים ידנית" את התמונה ל- $30 \times 30$  patch-ים חופפים, ונריץ discriminator "רגיל" (שבמוצא שלו יש נירון יחיד) על כל patch ונמצע על התוצאות.

\* ה-discriminator המושלם יוציא patch של 1-ים עבור תמונות שהן real ו-0-ים עבור תמונות שהן fake.




Fig 6: example for U-Net architecture

## פונקציות Loss:

הפונקציית loss הכוללת מורכבת ממספר פונקציות loss. נעבור על כל פונקציית loss ובסוף נציג את הפונקציית loss הכוללת.

### 1. Adversarial Loss:

ה-CycleGAN מורכב משני GAN-ים ולכן עבור כל GAN אנו מקבלים ה-adversarial loss.

$$(1) \mathcal{L}_{Adv}(G_Y, D_Y) = \mathbb{E}_{y \sim p_Y(y)} [\log(D_Y(y))] + \mathbb{E}_{x \sim p_X(x)} [\log(1 - D_Y(G_Y(x)))]$$




Fig 7: GAN that create Monet style images (Eq (1))

$$(2) \mathcal{L}_{Adv}(G_X, D_X) = \mathbb{E}_{x \sim p_X(x)} [\log(D_X(x))] + \mathbb{E}_{y \sim p_Y(y)} [\log(1 - D_X(G_X(y)))]$$




Fig 8: GAN that create real photos (Eq (2))

### 2. Cycle Consistency Loss:

כדי לצמצם את המרחב האפשרי אליו פונקציות המיפוי (generators) יכולים להתכנס וכדי "להכריח" את ה-generators ללמוד תכונות חשובות מ-input כך שיהיה ניתן לשחזר אותן.

$$(3) \mathcal{L}_{cyc}(G_X, G_Y) = \mathbb{E}_{x \sim p_X(x)} [\|G_X(G_Y(x)) - x\|_1] + \mathbb{E}_{y \sim p_Y(y)} [\|G_Y(G_X(y)) - y\|_1]$$






Fig 9: image translation cycles for cycle-consistency losses.

(a) reconstruction of Monet image and (b) reconstruction real photo image.

### .3 Identity loss

אם למשל יש לנו generator שממפה תמונות לתחום  $Y$  ונתנו לו כ-input תמונה מתחום זה אז היינו רוצים שהוא "יצליח להבין" שהוא קיבל תמונה מאותו תחום שאליו הוא ממפה ושיוציא את התמונה שהוא קיבל ב-input בתור ה-output שלו. זה "מכריח" את ה-generator ללמוד איזה תכונות מאפיינות את התחום שאליו הוא ממפה.

$$(4) \mathcal{L}_{id}(G_X) = \mathbb{E}_{x \sim p_X(x)} [\|G_X(x) - x\|_1]$$

$$(5) \mathcal{L}_{id}(G_Y) = \mathbb{E}_{y \sim p_Y(y)} [\|G_Y(y) - y\|_1]$$




Fig 10: (a) Identity forward of Monet image and (b) Identity forward of real photo image.

### :Total loss

$$(6) \mathcal{L}_{TOT}(G_X, G_Y, D_X, D_Y) = \mathcal{L}_{Adv}(G_Y, D_Y) + \mathcal{L}_{Adv}(G_X, D_X) + \lambda_{cyc} \mathcal{L}_{cyc}(G_X, G_Y) + \lambda_{id} (\mathcal{L}_{id}(G_X) + \mathcal{L}_{id}(G_Y))$$

המטרה: למצוא פונקציות מיפוי  $G_X^*, G_Y^*$  המקיימות:

$$(7) G_X^*, G_Y^* = \underset{G_X, G_Y}{\operatorname{argmin}} \max_{D_X, D_Y} \mathcal{L}_{TOT}(G_X, G_Y, D_X, D_Y)$$

# Challenges and Difficulties

## בעיות שיכולות להיווצר ב-CycleGAN:

### 1. דאטאסט "קטן מידי":

במקרה שבו יש לנו כמות קטנה יחסית של תמונות מאחד התחומים יכול להיווצר מצב שבו ה-discriminator נכנס ל-overfitting. בבעיה שלנו יש 300 ציורים של Monet ו-7038 תמונות שצולמו ע"י מצלמה. כלומר, יש לנו כמות קטנה של ציורי Monet ביחס לכמות התמונות מהעולם האמיתי. אם ה-discriminator של הציורי Monet יכנס ל-overfitting זה יבוא לידי ביטוי בכך שהוא ישנן את ה-300 ציורים שנתונים באימון ואם ניתן לו ציור Monet שלא מופיע באימון הוא יחשוב שזה לא ציור אמיתי.

\* בכל step בתוך אפוק במהלך האימון, אנו משתמשים גם בתמונה שצולמה ע"י מצלמה וגם ציור Monet כדי שבכל step יאומנו שני ה-GANים (האחד שיוצר ציורי Monet והשני שיוצר תמונות מהעולם האמיתי). כלומר, בכל אפוק צריכה להיות אותה כמות של ציורי Monet ואתה כמות של תמונות שצולמו ע"י מצלמה ומכיוון שאין את אותה כמות של תמונות מכל סוג אז או שיהיה מצב של under-sampling או של over-sampling.

#### דרכים לנסות לפתור את בעיית הדאטא הלא מאוזן:

- **Under-sampling**: צימצום התמונות שצולמו ע"י מצלמה. בכל אפוק אנו מתמשים ב-300 תמונות מכל סוג (ציורים או תמונות שצולמו ע"י מצלמה). החיסרון הוא שהמודל לא רואה את כל התמונות שצולמו ע"י מצלמה שיש לנו בדאטא במהלך כל אפוק בשלב האימון.
- **Over-sampling**: איזון הדאטא ע"י העלאת כמות התמונות מהתחום עם הכמות הקטנה יותר (ציורי Monet במקרה זה). ההעלאה של הכמות נעשית ע"י שכפול של התמונות הקיימות, כלומר, בכל אפוק אותה תמונה יכולה להופיע מספר פעמים. החיסרון פה הוא שהמודל ישנן את התמונות מהתחום הקטן ותר (הציורי Monet).

#### דרכים לנסות לפתור את בעיית ה-overfitting:

- **Augmentation**: במקרה של over-sampling על מנת למנוע את המצב שבו כל ציור Monet יכול להופיע מספר פעמים, ניסינו להשתמש באוגמנטציות אקראיות שפועלות על התמונות בשלב ה-preprocessing כלומר לפי ההכנסה לרשת. החיסרון שבשימוש באוגמנטציות הוא, שהן יכולות להשפיע על ההתפלגות ממנה באו התמונות שה-GAN "רואה" ובכך לפגוע בביצועים. האוגמנטציות שבהן השתמשנו הן: Flip, Crop ו-Rotation ב-Fig 11 ניתן לראות דוגמאות לאוגמנטציות.

\* על מנת שבכל אפוק יהיו אוגמנטציות אחרות ביצענו את זה באמצעות layers שמבצעות אוגמנטציות אקראיות שהן חלק מהמודל (כפי שלמדנו בעבודה 1), כאשר, שכבות אלה מופעלות רק בתהליך האימון ואין להן פרמטרים ללמידה. כלומר, layers אלה משמשות כ-preprocessing.

\* במקרה זה אנו רוצים לייצר ציורים (של Monet) ולכן נשתמש באוגמנטציות שלא פוגעות בגווי צבעים כדי שישפיעו כמה שפחות על ההתפלגות ממנה הגיעו הציורי Monet.




Fig 11: Original images and images with augmentations (Flip and rotation).

- **Diff-Augmentation [3]:** שיטה שבה משתמשים באוגמנטציות שניתן לייצג אותן באמצעות פונקציות גזירות כחלק מתהליך האימון כפי שמתאור ב-Fig 12. בהשוואה לאוגמנטציות "רגילות" (שבשלב ה-preprocessing) ב-Diff-augmentation האימון "מתחשב" באוגמנטציות אלה בתהליך ה-back propagation ולכן הדרישה היא שהן יהיו גזירות. החיסרון הוא שהאוגמנטציות הגזירות הן אוגמנטציות שמשנות את הגוונים בתמונה (brightness, contrast) או שהן מאפסות חלקים בתמונה (cutout) וזה עלול להטעות את ה-GAN.

ב-Fig 13 ניתן דוגמאות לאוגמנטציות: brightness, Translation, contrast and cutout.




Fig 12: diff augmentation in block diagram.

The function  $T(\cdot)$  it's the differentiable augmentation. The discriminator gets augmentation of the real image  $y$  and augmentation of the generated image  $G_Y(x)$ .




Fig 13: Original images and images with diff augmentation (brightness, contrast, and cutout).

## 2. Self-adversarial attack [4]:

ב-CycleGAN, באמצעות ה-cycle-consistency loss או "מכריחים" את ה-generator לשמור תכונות של ה-input במוצא כך שיהיה ניתן לשחזר את ה-input. הבעיה שיכולה להיווצר היא שהמודל "ישקיע" יותר בשיחזור מאשר בשימור על תכונות חשובות מה-input שנראות לעין. כלומר, הגבלת השיחזור יכולה לגרום ל-generator "להחביא" את התכונות החשובות לשיחזור בתוך רעש במוצא שלא ניתן לזהות ע"י העין האנושית או ע"י ה-discriminator.

\* בפועל בעיה זו באה לידי ביטוי בכך שהשחזור לא חסין להוספת רעש, כלומר, אם נוסיף רעש למוצא ה-generator ואז ננסה לשחזר את ה-input באמצעות ה-generator השני נקבל תמונה שלא נראית בכלל כמו ה-input כלומר, לא נצליח לשחזר (זה ינבע מכך שהתכונות החשובות נשמרות בתוך רעש בתמונה). ב-Fig 14 ניתן לראות דוגמה לבעיה זו שלקוחה מהמאמר [4].




Fig 14: example of reconstruction of CycleGAN that trained to create segmentation. The noise is gaussian noise  $N(0, 0.08)$ .

ב-Fig 15 ניתן לראות איך תוספת רעש משפיעה על השיחזור של ציור Monet של ה-CycleGAN בבעיה שלנו. המודל שמוצג הוא CycleGAN מאומן ללא אוגמנטציות עם over-sampling אך מקבלים את אותה המסקנה גם עבור שאר המודלים שאומנו. מה-Fig 15 נובע שהשיחזור חסין להוספת רעש, כלומר, בעיה זו לא קיימת במקרה זה.




Fig 15: example of reconstruction of CycleGAN that trained to create segmentation. The noise is gaussian noise  $N(0, 0.08)$ .

\*דרך להתמודד עם הבעיה הזו היא להכניס רעש ל-cycle consistency loss במתואר במשוואה (8), כדי להפוך את תהליך השיחזור להיות חסין לרעש ולמנוע מה-generator "להחביא" את התוכנות של ה-input תוך רעש.

$$(8) \mathcal{L}_{cyc}(G_X, G_Y) = \mathbb{E}_{x \sim p_X(x)} [\|G_X(G_Y(x) + noise) - x\|_1] + \mathbb{E}_{y \sim p_Y(y)} [\|G_Y(G_X(y) + noise) - y\|_1]$$

\*אך במקרה זה כפי שראינו מקודם, תהליך השיחזור יחסית חסין לרעש.

# Experiments

המטרה שלנו באתגר ה-kaggle המוצג בדוח זה היא למצוא את המודל שנותן את ה-MiFID score הנמוך ביותר (הביצועים הטובים ביותר).  
על מנת למצוא את המודל הטוב ביותר במובן זה אימנו את המודלים הבאים:

1. CycleGAN+Os (Over-sampling)
2. CycleGAN+Us (Under-sampling)
3. CycleGAN+Os+Aug (Augmentation)
4. CycleGAN+Us+Aug
5. CycleGAN+Os+DiffAug (Diff-Augmentation)
6. CycleGAN+Us+DiffAug

מדדים להערכת הביצועים:

- MiFID (מוסבר בפירוט בסוף הפרק) – מדד הסתברותי שמאפשר להעריך כמותית עד כמה הציורים שנוצרים ע"י ה-generator באמת "נראים" כמו ציורי Monet ונרצה את המודל שנותן את הערך המינימלי של מדד זה.  
\*את מדד MiFID המחושב ב-Kaggle מחשבים עם ציורי Monet שלא נתונים לנו ולכן, לא ניתן להעריך במהלך האימון את ה-score האמיתי שאנו צריכים לקבל.
- Loss functions - באמצעות "learning curves", מאפשרים לנו להבין האם המודל אכן "הצליח ללמוד" וזה יבוא לידי ביטוי בהתנהגות של ה-loss functions לאורך האימון.
- \*המודל שקיבל את ה-MiFID score הנמוך ביותר (הטוב ביותר) הוא CycleGAN+Os ולכן נציג עבורו את כל הגרפים של האימון ובסוף מופיעה טבלה שמכילה את ה-MiFID score שקיבל כל מודל.
- \*אנו מציגים את ה-learning curves רק עבור המודל שנתן את הביצועים הטובים ביותר כדי לקבל דוח יותר קריא ומסודר שמכיל את הפרטים החשובים.
- \*נזכיר שההסבר על ה-overfitting שיכול להיגרם במהלך אימון ה-discriminator כתוצאה מהחוסר איזון בדאטא (יש הרבה יותר תמונות שצולמו ע"י מצלמה מציורי Monet) מוסבר בפרק Challenges and Difficulties.

## :Learning curves

לפי משוואה (7) אנו רוצים במהלך האימון להביא למקסימום את ה-Loss לפי ה-discriminator ולמינימום את ה-Loss לפי ה-generator. היינו מעדיפים שנצטרך להביא למינימום את כל ה-Loss-ים על מנת שנוכל להשתמש ב-gradient descent בכל המקרים.

לצורך כך, כאשר אנו מאמנים את ה-discriminator נפתור את בעיית המינימיזציה הבאה:

$$(9) \min_{D_Y} \left\{ - \left( \mathbb{E}_{y \sim p_Y(y)} [\log(D_Y(y))] \right) + \mathbb{E}_{x \sim p_X(x)} [\log(1 - D_Y(G_Y(x)))] \right\}$$

Discriminator loss  
(part of the adversarial loss for the discriminator training)

כלומר, מוסיפים מינוס. וה-generator loss, שזה החלק מה-adversarial loss שמביאים למינימום באימון ה-generator, מוגדר ע"י:

$$(10) \operatorname{argmin}_{G_Y} \left\{ \mathbb{E}_{x \sim p_X(x)} [\log(1 - D_Y(G_Y(x)))] \right\}$$

generator loss  
(part of the adversarial loss for the generator training)

### הערות/מסקנות:

- ב-Fig 16 ניתן לראות את ה-loss-ים שהתקבלו עבור המודל CycleGAN+Os.
- בגרף (e) ניתן לראות את ה-cycle loss שהולך וקטן עם האימון, כלומר ה-generator ימים מצליחים ללמוד בצורה יותר טובה תכונות מה-input שמאפשרות שיחזור.
  - בגרף (a) ניתן לראות את ה-generator loss עבור תמונות photo (תמונות שנוצרו ע"י מצלמה) וב-(b) את ה-photo discriminator loss. נשים לב, שבהתחלה שניהם יורדים ואז ה-discriminator loss מתחיל קצת לעלות (כלומר, ה-generator "מצליח לעבוד" על ה-discriminator). מסקנות דומות ניתן להסיק גם עבור ה-loss-ים של Monet.



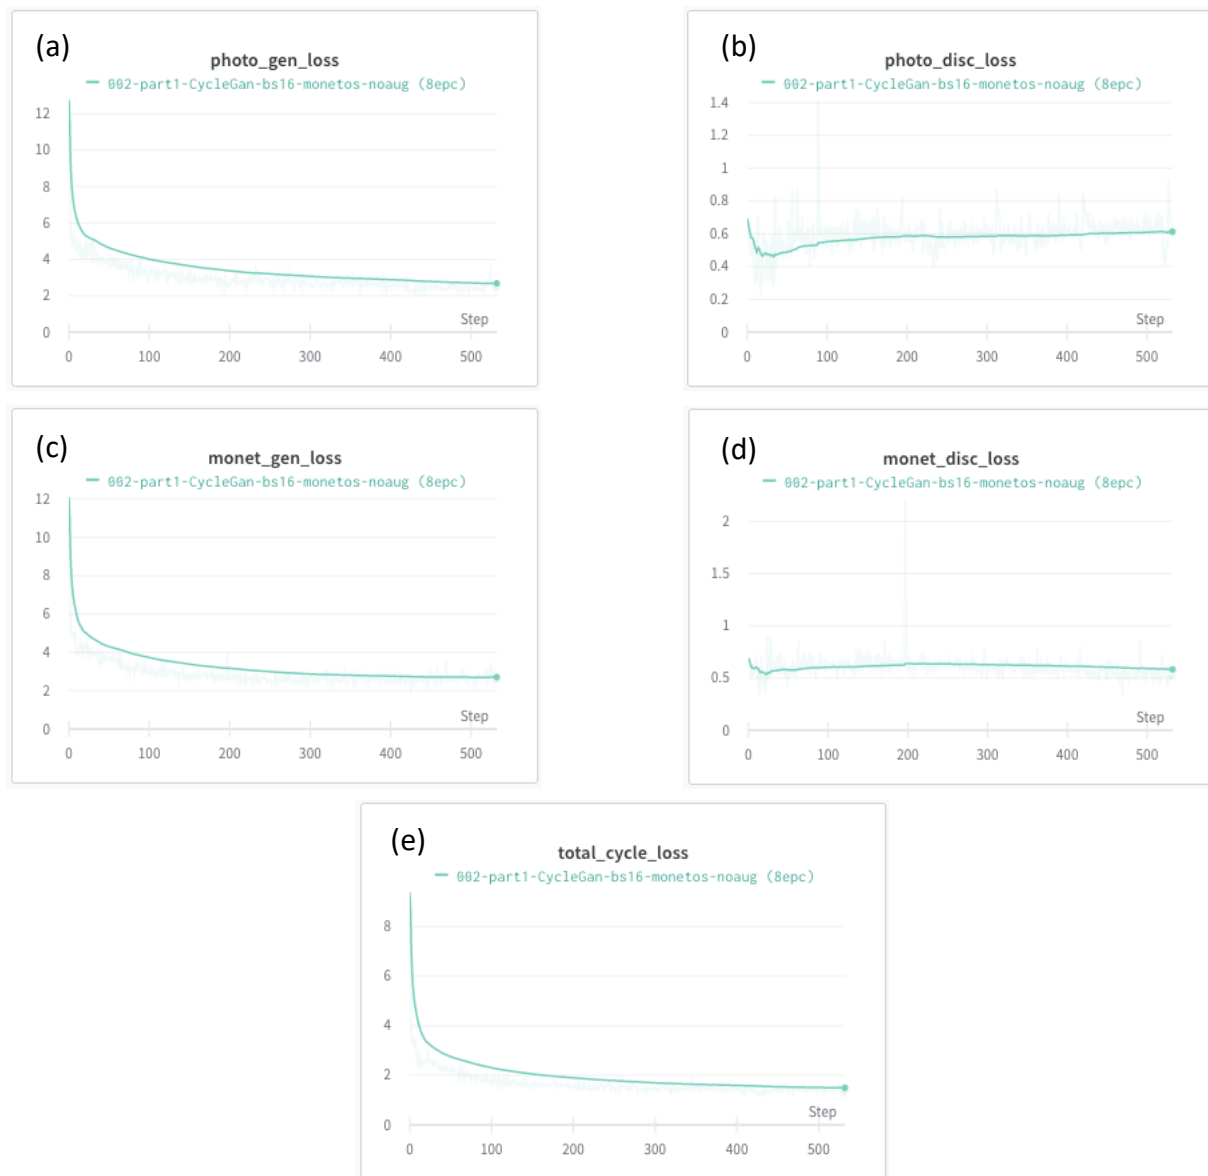


Fig 16: (a) photo (camera image) generator loss (b) photo discriminator loss (c) Monet generator loss (d) Monet discriminator loss (e) Cycle Consistency Loss (photo +Monet).



## מדד להערכת הביצועים-MiFID :

אנו רוצים ליצור ציורים "שנראים" כמו ציורים בסגנון מונה (Monet) ולכן, אנו צריכים מדד שיוכל להגיד לנו עד כמה הציורים שיצרנו "קרובים" לציורי Monet. המדד נקרא **MiFID** (Memorization-informed Fréchet Inception Distance) שמבוסס על המדד FID (Fréchet Inception Distance).

**FID:** מדד המשמש להערכת איכות התמונות שנוצרו על ידי מודל יוצר (generative model).

- בשלב הראשון משתמשים ברשת pretrained שנקראת Inception network כדי לחלץ פיצרים עבור כל תמונה (התמונות האמיתיות והתמונות שנוצרו מה-generator).
- ממדלים את הסתברות הדאטא של הפיצרים שחולצו באמצעות מודל גאוסי רב מיימדי.
- נסמן:  $\mathcal{N}(\mu_r, \Sigma_r)$  את ההסתברות הגאוסית של הפיצרים המתאימים לתמונות האמיתיות וב-  $\mathcal{N}(\mu_g, \Sigma_g)$  את ההסתברות הגאוסית של הפיצרים המתאימים לתמונות שיוצרו ע"י ה-generator.
- ולבסוף מחשבים את המדד FID לפי הנוסחא הבאה:

$$(11) FID = \|\mu_r - \mu_g\|^2 + Tr\left(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{\frac{1}{2}}\right)$$

\*נרצה שה-FID יהיה כמה שיותר קטן.

**MiFID:** מדד מבוסס על ה-FID ומעניש במקרה שבו יש שינון של התמונות האמיתיות מהסט אימון. כלומר, יש גורם תיקון שמטרתו היא "להעניש" ולהעלות את המדד במקרה שבו ה-generator משנן את הסט אימון ולומד לייצר רק את התמונות האמיתיות שמופיעות באימון. הנוסחא ל-MiFID נתונה ע"י:

$$(12) MiFID = FID \cdot \frac{1}{d_{thr}}$$

\*ה-FID הוא מדד של מרחק בין הסתברויות והתוספת של הגורם "ענישה" באה למנוע מצב שבו אנשים מגישים ל-Kaggle את הציורי Monet מה-train כדי לקבל FID נמוך.

\*התמונות האמיתיות, ציורי Monet במקרה זה, המשמשות לחישוב ה-FID ב-Kaggle אלה לא רק הציורי Monet הנתונים בסט אימון, כלומר, יש סט ציורים שונה מזה של האימון המשמש להערכת המדד ולכן, לא נוכל לחשב אותו בצורה מדויקת במהלך האימון ונוכל לחשב אותו רק כאשר נבצע הגשה ל-Kaggle.

## דרך החישוב של $d_{thr}$ :

נסמן: ב-  $f_{rj}$  – את וקטור הפיצורים שחולצו ע"י ה-Inception network עבור התמונה האמתית (ציור Monet אמיתי) ה- $j$ .

ב-  $f_{gi}$  – את וקטור הפיצורים שחולצו ע"י ה-Inception network עבור התמונה ה- $i$  שנוצרה ע"י ה-generator (ציור Monet שנוצר ע"י ה-generator).

שלב 1: עבור כל זוג שמורכב מתמונה אמיתית  $j$  ומתמונה שנוצרה ע"י  $i$  generator מחושב המרחק בין התמונות בצורה הבאה:

$$(13) \quad d_{ij} = 1 - \frac{f_{gi} \cdot f_{rj}}{|f_{gi}| |f_{rj}|}$$

כאשר, הביטוי  $\frac{f_{gi} \cdot f_{rj}}{|f_{gi}| |f_{rj}|}$  שווה לקוסינוס הזווית בין שני הוקטורים (מהנוסחא של מכפלה פנימית) כלומר, המרחק בין שתי התמונות יותר קטן ככל שהזווית שבין שני וקטורי הפיצורים יותר קטנה.

שלב 2: עבור כל תמונה  $i$  שנוצרה ע"י ה-generator מוצאים את התמונה האמתית  $j$  שהמרחק ביניהן הוא המינימלי בהשוואה למרחק משאר התמונות האמיתיות ואז ממצעים על כל המרחקים המינימלים על פני כל התמונות שנוצרו ע"י ה-generator. מתמטית אנו מחשבים את המחק המינימלי הממוצע על פני כל התמונות שנוצרו ע"י ה-generator הצורה הבאה:

$$(14) \quad d = \frac{1}{N} \sum_i \min_j d_{ij}$$

כאשר,  $N$  מייצג את מספר התמונות שנוצרו ע"י ה-generator.

שלב 3: מגדירים ערך סף  $0 < \varepsilon < 1$  וכאשר המרחק המינימלי הממוצע  $d$  קטן ממנו זה אומר שהתמונות שנוצרו ע"י ה-generator דומות מידי לתמונות האמיתיות. מבחינה מתמטית  $d_{thr}$  מחושב כך:

$$(15) \quad d_{thr} = \begin{cases} d, & \text{if } d < \varepsilon \\ 1, & \text{else} \end{cases}$$

# Results

## :MiFID Score

הטבלה שמופיעה מטה מציגה את ה-MiFID Score שהתקבל עבור כל אחד מהמודלים שאומן.

Model name	CycleGAN +Os	CycleGAN +Us	CycleGAN +Os+Aug	CycleGAN +Us+Aug	CycleGAN +Os+DiffAug	CycleGAN +Us+DiffAug
MiFID Score	38.553	38.674	47.369	48.475	54.991	59.493

המודל שקיבל את ה-MiFID score הנמוך ביותר (הטוב ביותר) הוא CycleGAN+Os.

## דוגמאות ליצירת ציורי Monet עם המודל CycleGAN+Os:

Photo (camera image)



Generated Monet image  $G_Y(x)$




Fig 17: examples for "Monet images" that generated by the generator of CycleGAN+Os model.


# Conclusions and Summary

- המודל שקיבל את ה-MiFID הטוב ביותר (הנמוך ביותר) הוא CycleGAN+Os.
- ניתן לראות שהאוגמנטציות (בשני הסוגים) לא עזרו לשפר את הביצועים. ככל הנראה הסיבה לכך היא שאוגמנטציות משנות את ההתפלגות ממנה הציורי Monet הגיעו וכתוצאה מכך הביצועים של ה-GAN נפגעים.
- ניתן לראות שבאופן כללי עם שימוש ב-Under sampling מקבלים ביצועים פחות טובים מאשר Over-sampling. אומנם ב-Over-sampling יש סכנה שמודל ישנן את ה-300 ציורי Monet אך היתרון הוא שהמודל מתאמן על יותר תמונות שצולמו ע"י מצלמה ויתרון זה מאפשר ככל הנראה למודל לת ביצועים טובים.

מקום 16 בתחרות הכוללת נכון לתאריך 09/08/2022

16

Vincent GAN Gogh



38.55316

# References

- [1] Zhu, Jun-Yan, et al. "Unpaired image-to-image translation using cycle-consistent adversarial networks." Proceedings of the IEEE international conference on computer vision. 2017
- [2] Isola, Phillip, et al. "Image-to-image translation with conditional adversarial networks." Proceedings of the IEEE conference on computer vision and pattern recognition. 2017
- [3] Zhao, Shengyu, et al. "Differentiable augmentation for data-efficient gan training." Advances in Neural Information Processing Systems 33 (2020)(
- [4] Bashkirova, Dina, Ben Usman, and Kate Saenko. "Adversarial self-defense for cycle-consistent GANs." Advances in Neural Information Processing Systems 32 (2019)(